Raport
Przygotowanie i Walidacja Danych

Maria Banaszkiewicz, Ewa Ejnik, Dawid Kalinowski
Grupa S42-02

Styczeń 2026

1 Samodzielne pozyskanie danych

Zbiór danych pozyskany przez nas w celu wykonania jego analizy to:

- *120 Years of Olympic History* - zbiór pochodzący z wtórnego źródła jakim jest kaggle.com;

Zbiór danych wykorzystany do imputacji braków:

- *Height Evolution of adult height over time* - zbiór pochodzący z wtórnego źródła jakim jest ncdrisc.org;

2 Ocena jakości danych

- *120 Years of Olympic History*

Zbiór danych zawiera **271 116** rekordów. Obejmuje dane dotyczące **135 571** sportowców biorących udział w letnich lub zimowych Igrzyskach Olimpijskich w latach **1896-2016**. Zawiera następujące dane:

- imię zawodnika,
- nazwisko zawodnika,
- płeć zawodnika,
- wiek zawodnika,
- wzrost zawodnika [cm],
- wagę zawodnika [kg],
- kraj reprezentowany przez zawodnika,
- dyscyplinę, którą reprezentuje zawodnik,
- rok, w którym zawodnik startował w igrzyskach,
- miasto, w którym te igrzyska miały miejsce,
- informację o tym czy zawodnik zdobył medal, a jeśli tak to jaki.

Lista kolumn w zbiorze *120 Years of Olympic History*:

- ID
- Name
- Sex
- Age
- Height
- Weight
- Team
- NOC*
- Games
- Year
- Season
- City
- Sport
- Event
- Medal

NOC* - National Olympic Commitees

Wartości w wybranych kolumnach zbioru:

- Sex
  - M - Male
  - F - Female
- Season
  - Summer
  - Winter
- Medal
  - Gold
  - Silver
  - Bronze

Zbiór jest w zdecydowanej większości zgodny z prawdą, z małymi uwagami:

- w przypadku, gdy sportowiec zdobył medal, który z różnych przyczyn, np. za stosowanie dopingu, został mu później odebrany, w zbiorze dalej widnieje jako zdobywca medalu,
- w przypadku sportów zespołowych, gdy drużyna zdobędzie medal, oficjalnie jest to traktowane jako 1 medal. Tymczasem w wykorzystywanym przez nas zbiorze przypisuje się medal wszystkim zawodnikom należącym do drużyny, np. w piłce siatkowej przypisywany jest wszystkim 12 zawodnikom, aktywnym na boisku, jak i rezerwowym.

W związku z czym nie należy porównywać liczby zdobytych medali przez dany kraj, co jest popularną statystyką w Internecie, z danymi pochodzącymi z wykorzystanego przez nas zbioru. Przykładowo, na oficjalnej stronie olympics.com podana jest informacja, że w **2016** roku USA zdobyły łącznie **121** medali, a liczba zsumowanych medali dla tego państwa w tym samym roku w wykorzystanym przez nas zbiorze to **264**.

Zbiór posiada braki danych w następujących kolumnach:

- **Age:** 9 474 braki (**3,49%** rekordów)
- **Height:** 60 171 braków (**22,19%** rekordów)
- **Weight:** 62 875 braków (**23,19%** rekordów)

W kolumnie Medal znajduje się 231 333 (**85,32%)** rekordy NA, co nie oznacza braku danych, lecz to, że sportowiec nie zdobył medalu.

3 Czyszczenie i porządkowanie danych

3.1 Podział zmiennych według poziomu pomiaru

- Poziom nominalny
  - ID
  - Name
  - Sex
  - Team
  - NOC
  - Games
  - Season
  - City
  - Sport
  - Event
- Poziom porządkowy
  - Medal
- Poziom przedziałowy
  - Year
- Poziom stosunkowy
  - Age
  - Height
  - Weight

3.2 Czyszczenie danych

W ramach etapu czyszczenia danych przeprowadzono:

- weryfikację typów danych zmiennych,
- analizę kompletności danych,
- sprawdzenie minimalnych i maksymalnych wartości zmiennych ilościowych,
- kontrolę duplikatów rekordów.

Tablica z charakterystykami zmiennych

Zmienna	Typ	Liczba unikatowych wartości	Liczba braków	Minimum	Maksimum
ID	numeric	135571	0	1	135571
Name	character	134732	0	NA	NA
Sex	character	2	0	NA	NA
Age	numeric	74	9474	10	97
Height	numeric	95	60171	127	226
Weight	numeric	220	62875	25	214
Team	character	1184	0	NA	NA
NOC	character	230	0	NA	NA
Games	character	51	0	NA	NA
Year	numeric	35	0	1896	2016
Season	character	2	0	NA	NA
City	character	42	0	NA	NA
Sport	character	66	0	NA	NA
Event	character	765	0	NA	NA
Medal	character	3	231333	NA	NA

3.3 Porządkowanie danych

W celu jednoznacznego rozróżnienia braków danych od braku zdarzenia, została dodana nowa kolumna **Medal status**, w której wartości NA z kolumny *Medal* zastąpiła etykieta *No Medal*, oznaczająca brak zdobycia medalu przez zawodnika, a nie brak informacji w danych źródłowych.

4 Eksploracyjna analiza danych

4.1 Badanie rozkładów zmiennych

W ramach eksploracyjnej analizy danych przeprowadzono analizę rozkładów zmiennych ilościowych:

- wieku (Age),
- wagi (Weight),
- wzrostu (Height[m]*),
- BMI (BMI*).

*Kolumny Height[m] i BMI zostały stworzone na potrzebę tejże analizy.

4.1.1 Analiza graficzna

Rozkłady przedstawiono graficznie za pomocą wykresów pudełkowych (boxplot), co umożliwiło identyfikację median, kwartylów oraz wartości odstających.

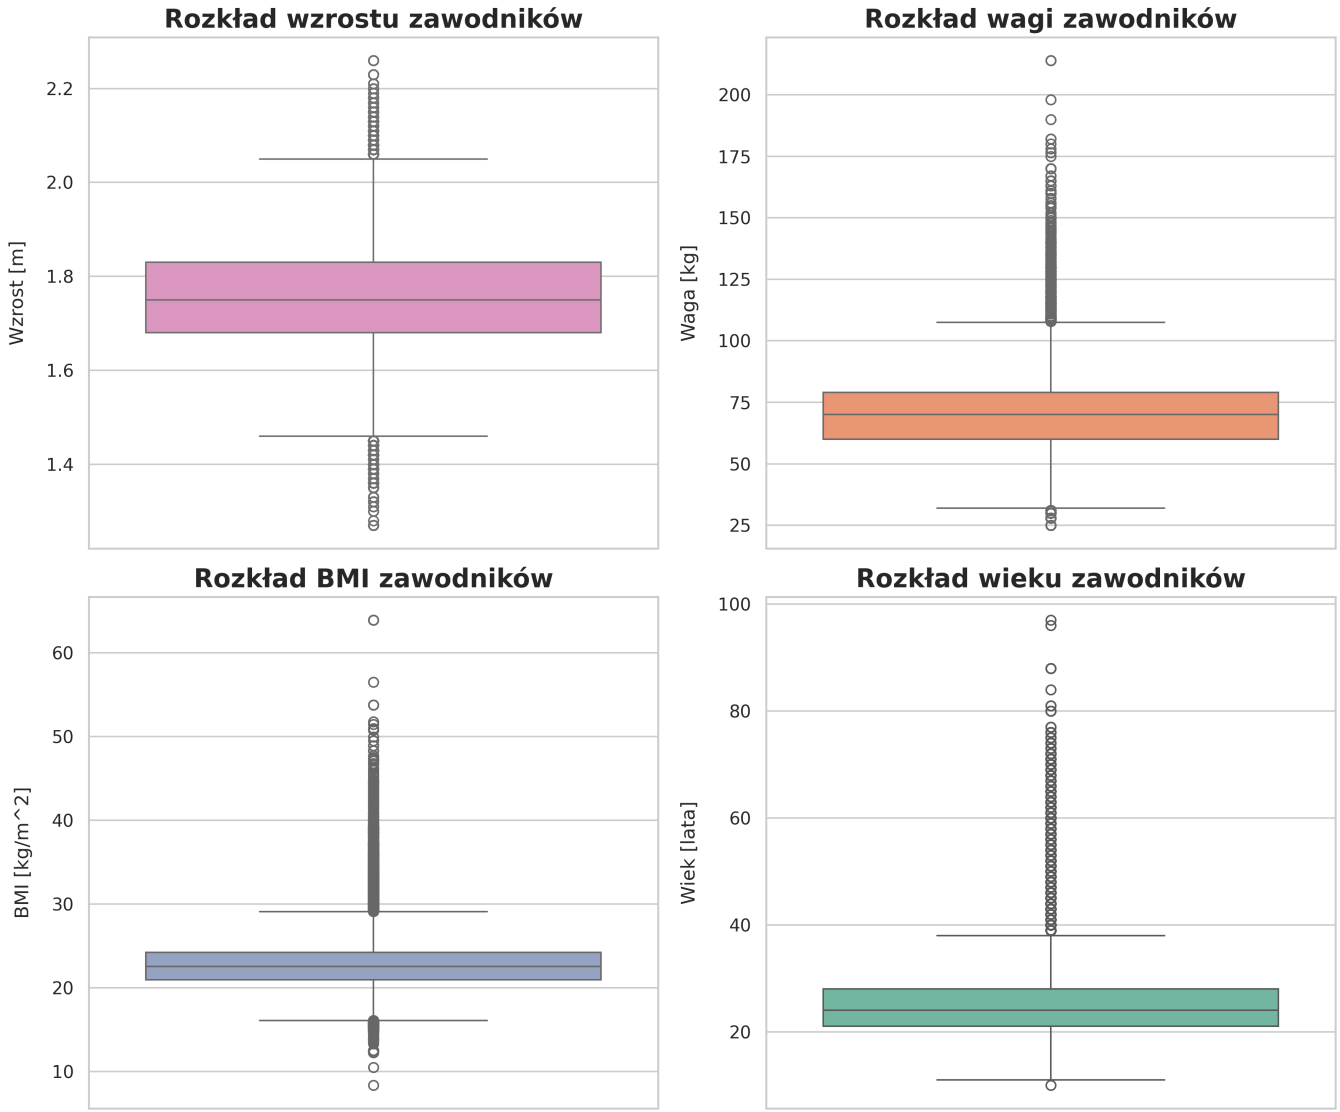

Rysunek 1: Wykresy rozkładów zmiennych ilościowych

4.1.2 Analiza parametryczna

Uzupełniająco wykonano analizę parametryczną, obejmującą obliczenie podstawowych statystyk opisowych: średniej, mediany, odchylenia standardowego, wartości minimalnych i maksymalnych oraz kwartylów. Wyniki te pozwalają na ilościową charakterystykę zmienności badanych cech fizycznych zawodników.

Uwaga: Z powrotem używamy kolumny Height, a nie Height[m].

	Age	Height	Weight	BMI
count	261642.000000	210945.000000	208241.000000	206853.000000
mean	25.556898	175.338970	70.702393	22.784520
std	6.393561	10.518462	14.348020	2.912067
min	10.000000	127.000000	25.000000	8.360954
25%	21.000000	168.000000	60.000000	20.957171
50%	24.000000	175.000000	70.000000	22.530864
75%	28.000000	183.000000	79.000000	24.212293
max	97.000000	226.000000	214.000000	63.901580

Rysunek 2: Statystyki opisowe

4.1.3 Analiza tabelaryczna

Przeprowadzono analizę struktury danych w formie tabelarycznej, obejmującą:

- rozkład płci (Sex),
- rozkład zdobytych medali (Medal),
- rozkład dyscyplin sportowych (Sport).

```
Sex
M    196594
F     74522
Name: count, dtype: int64
```

```
Medal
Gold      13372
Bronze    13295
Silver    13116
Name: count, dtype: int64
```

```
Sport
Athletics               38624
Gymnastics              26707
Swimming                23195
Shooting                11448
Cycling                 10859
Fencing                 10735
Rowing                  10595
Cross Country Skiing     9133
Alpine Skiing            8829
Wrestling                7154
Football                 6745
Sailing                  6586
Equestrianism            6344
Canoeing                 6171
Boxing                   6047
Name: count, dtype: int64
```

Rysunek 3: Analiza struktury

Analiza tabelaryczna pozwoliła na ilościową ocenę dominujących wartości.

4.2 Badanie współzależności między zmiennymi

W celu analizy zależności pomiędzy zmiennymi ilościowymi obliczono macierz korelacji dla cech fizycznych:

- wiek (Age),
- wzrost (Height),
- waga (Weight),
- BMI (BMI).

4.2.1 Analiza tabelaryczna

	Age	Height	Weight	BMI
Age	1.000000	0.138246	0.212069	0.218230
Height	0.138246	1.000000	0.796213	0.335855
Weight	0.212069	0.796213	1.000000	0.830461
BMI	0.218230	0.335855	0.830461	1.000000

Rysunek 4: Macierz korelacji cech fizycznych

4.2.2 Analiza graficzna

W ramach analizy graficznej wykonano wykres mapa cieplna (heat map) korelacji.

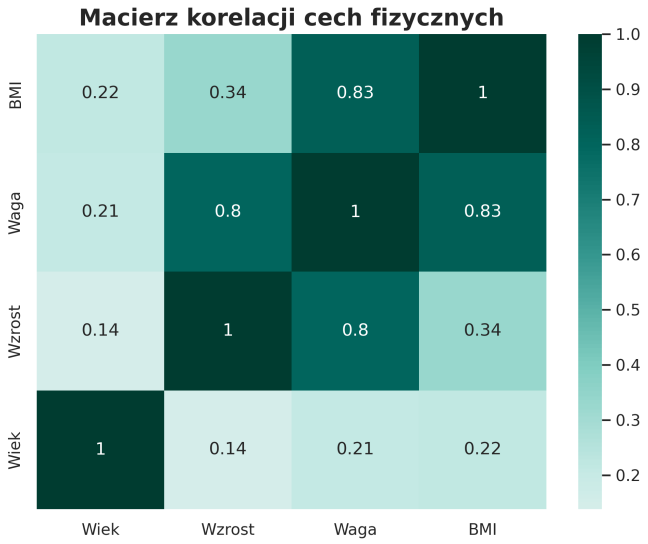

Rysunek 5: Macierz korelacji cech fizycznych

Dodatkowo przeanalizowano zależności strukturalne pomiędzy:

- wskaźnikiem BMI a reprezentowaną dyscypliną sportową,
- cechami fizycznymi a zdobyciem medalu,
- wiekiem zawodnika a zdobywaniem przez niego medali.

Analiza wykazała istnienie zależności pomiędzy budową ciała zawodników a charakterem dyscyplin sportowych, co potwierdza biologiczno-strukturalny charakter obserwowanych rozkładów.

4.3 Podsumowanie

Eksploracyjna analiza danych przeprowadzona w sposób tabelaryczny, parametryczny i graficzny pozwoliła na wielowymiarową charakterystykę zbioru danych, identyfikację podstawowych prawidłowości strukturalnych oraz weryfikację jakości i spójności danych. Uzyskane wyniki stanowią podstawę do dalszych analiz statystycznych i wnioskowania.

5 Przekształcanie zmiennych

W celu rozszerzenia możliwości analitycznych zbioru danych utworzono dodatkową zmienną BMI, obliczaną według wzoru:

$$BMI = \frac{waga\ [kg]}{(wzrost\ [m])^2}.$$

Umożliwia to analizę relacji pomiędzy budową ciała zawodników a reprezentowaną dyscypliną sportową oraz pozostałymi zmiennymi opisowymi.

Dodatkowo na potrzebę obliczenia BMI oraz stworzenia wykresu rozkładu wzrostu zawodników stworzono kolumnę Height[m], w której umieszczono wzrost wyrażony metrach.

6 Analiza danych nietypowych

Analiza danych nietypowych została przeprowadzona w celu identyfikacji obserwacji odstających (outlierów) oraz anomalii strukturalnych, które mogłyby wskazywać na błędy danych lub nietypowe, lecz empirycznie uzasadnione przypadki.

6.1 Identyfikacja outlierów statystycznych

W pierwszym etapie zastosowano metodę rozstępu międzykwartylowego (IQR) do wyznaczenia zakresów typowych wartości dla zmiennych ilościowych: wieku (Age), wzrostu (Height), wagi (Weight) oraz BMI. Uzyskano następujące zakresy referencyjne oraz liczbę outlierów:

Zmienna	Zakres QLR	Liczba outlierów
Age	10,5–38,5	10317
Height	145,5-205,5	1338
Weight	31,5-107,5	3237
BMI	16,07-29,09	6276

Dodatkowo przeprowadzono analizę standaryzowanych odchyleń (z-score), przyjmując próg $|z| > 3$ jako kryterium identyfikacji obserwacji nietypowych. Uzyskano następujące liczby obserwacji odstających:

- **Age:** 2,619
- **Height:** 855
- **Weight:** 2,113
- **BMI:** 2,827

Wysoka liczba obserwacji klasyfikowanych jako outliery w ujęciu statystycznym wynika z dużej liczebności próby oraz naturalnej heterogeniczności populacji sportowców olimpijskich, obejmującej szerokie spektrum dyscyplin sportowych, kategorii wagowych, poziomów specjalizacji oraz okresów historycznych.

6.2 Sprawdzenie zgodności skrajnych wartości z rzeczywistością

Maksymalny wiek zawodnika w zbiorze danych wynosi **97 lat**. Był nim John Quincy Adams Ward, uczestnik Igrzysk Olimpijskich z 1928 roku w kategorii rzeźbiarstwo (art competitions). Analiza struktury wiekowej wykazała, że zdecydowana większość (77,20%) zawodników w przedziale wiekowym 60–97 lat uczestniczyła w konkurencjach artystycznych.

Minimalny wiek zawodnika wynosi **10 lat** i dotyczy Dimitrios Loundras, uczestnika Igrzysk Olimpijskich z 1896 roku w kategorii gimnastyka. Analiza zawodników w wieku 10–15 lat wykazała, że dominującymi dyscyplinami w tym przedziale wiekowym są gimnastyka (39,05%) oraz pływanie (42,71%).

Najwyższy wzrost w zbiorze danych wynosi **226 cm** i dotyczy Yao Ming, zawodnika w kategorii koszykówka. Analiza zawodników o wzroście 200–226 cm wykazała, że zdecydowana większość z nich reprezentuje koszykówkę (36.27%) oraz piłkę siatkową (16,2%).

Najniższy wzrost w zbiorze danych wynosi **127 cm** i dotyczy Rosario Briones, zawodniczki gimnastyki. W grupie zawodników o wzroście 127–150 cm dominującą dyscypliną jest gimnastyka (73,17%).

Minimalna waga w zbiorze danych wynosi **25 kg** i dotyczy zawodniczki Choi Gyong-hui, startującej w kategorii gimnastyka. Analiza struktury dyscyplin w grupie zawodników o wadze 25–50 kg wykazała, że zdecydowana większość obserwacji w tym przedziale dotyczy gimnastyki (44,03%).

Maksymalna waga w zbiorze danych wynosi **214 kg** i dotyczy Ricardo Blas Jr., zawodnika startującego w kategorii judo. Analiza zawodników o masie ciała 145–214 kg wykazała dominację dyscyplin takich jak podnoszenie ciężarów (54,11%) oraz judo (18,49%).

Przeprowadzona analiza potwierdza, że skrajne wartości zmiennych ilościowych mają charakter empirycznie uzasadniony i wynikają ze struktury dyscyplin sportowych oraz historycznego charakteru igrzysk olimpijskich. Wartości te zostały zaklasyfikowane jako naturalne, a nie jako błędy danych, więc nie były usuwane ani korygowane.

6.3 Analiza anomalii strukturalnych

W kolejnym etapie przeprowadzono analizę anomalii strukturalnych, polegającą na identyfikacji nietypowych kombinacji cech fizycznych, które mogłyby wskazywać na błędy danych lub niespójności logiczne. Sprawdzono w szczególności przypadki:

- bardzo młodego wieku przy wysokiej masie ciała,
- niskiego wzrostu przy wysokiej wadze.

Analiza nie wykazała występowania takich kombinacji danych (liczba przypadków w obu kategoriach: 0), co potwierdza spójność logiczną zbioru danych oraz brak anomalii semantycznych.

6.4 Analiza graficzna danych nietypowych

W celu wizualnej identyfikacji obserwacji nietypowych oraz analizy struktury danych wykonano wykresy punktowe (scatter plots) przedstawiające zależności pomiędzy wybranymi parami zmiennych ilościowych:

- wiek (Age) i BMI
- wzrost (Height) i waga (Weight)

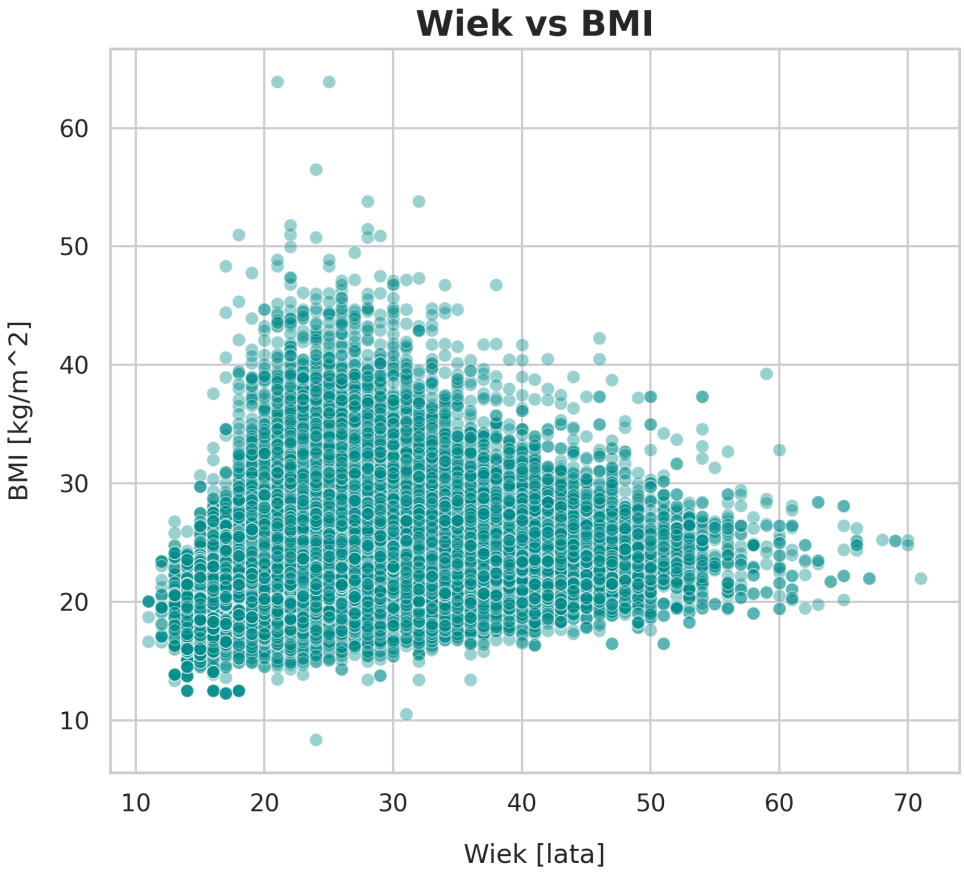

Rysunek 6: Anomalie wiek - BMI

Na wykresie zależności wiek-BMI widoczna jest ciągła struktura rozkładu punktów, bez występowania izolowanych, oderwanych obserwacji, które mogłyby wskazywać na błędy danych. Obserwacje skrajne tworzą spójne obszary rozkładu, co potwierdza ich strukturalny, a nie losowy charakter. Wartości ekstremalne BMI występują głównie w określonych przedziałach wiekowych, co wskazuje na biologicznie i sportowo uwarunkowaną zmienność cech fizycznych zawodników.

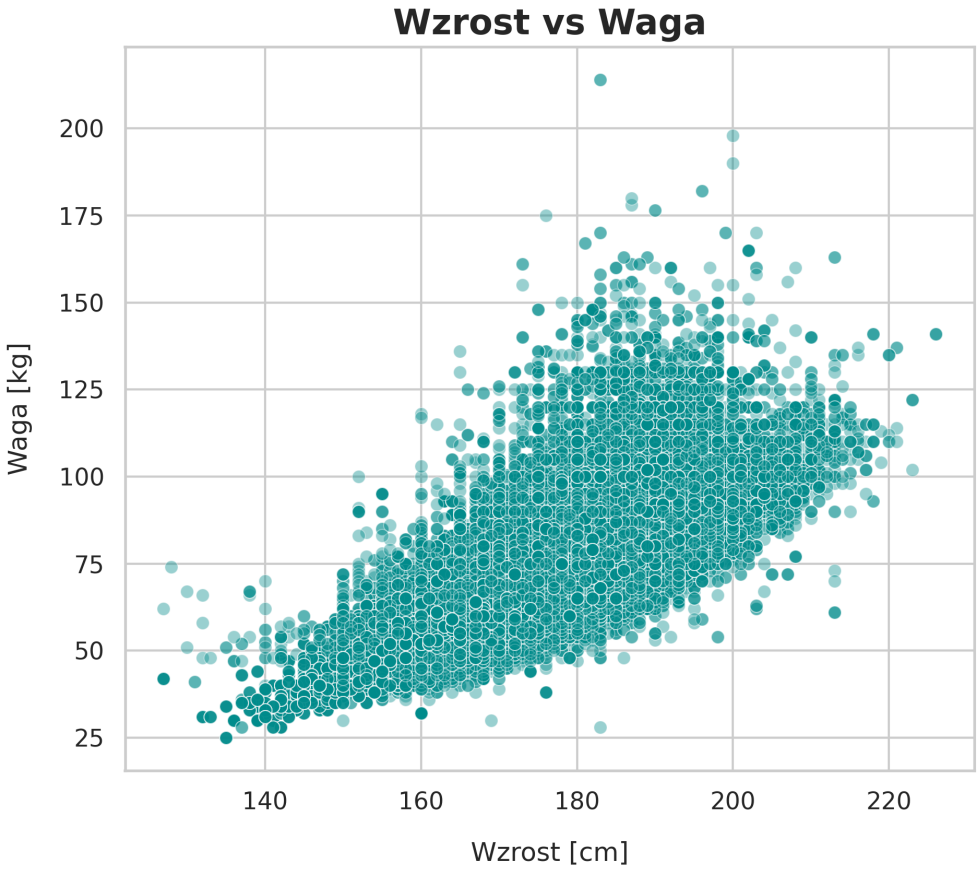

Rysunek 7: Anomalie wzrost - wiek

Wykres zależności wzrost–waga ujawnia wyraźną, dodatnią zależność pomiędzy zmiennymi, odpowiadającą naturze. Obserwacje nietypowe nie występują w postaci pojedynczych, izolowanych punktów, lecz tworzą strukturalne skupienia odpowiadające specyficznym profilom fizycznym charakterystycznym dla wybranych dyscyplin sportowych (np. koszykówka, podnoszenie ciężarów, judo).

Analiza graficzna potwierdza, że dane nietypowe nie mają charakteru błędów pomiarowych ani błędów kodowania danych, lecz wynikają z rzeczywistej struktury populacji sportowców olimpijskich. Wykresy stanowią wizualne potwierdzenie, że obserwacje skrajne są częścią ciągłych rozkładów, a nie anomaliami losowymi, co uzasadnia ich zachowanie w dalszych etapach analizy.

6.5 Interpretacja i wnioski

Zidentyfikowane obserwacje odstające mają w zdecydowanej większości charakter outlierów strukturalnych, a nie błędów danych. Ich występowanie wynika ze:

- specyfiki dyscyplin sportowych (np. gimnastyka, podnoszenie ciężarów, koszykówka, judo),
- istnienia konkurencji artystycznych w historii igrzysk olimpijskich,
- obecności sportów zespołowych i indywidualnych,
- biologicznego zróżnicowania cech fizycznych zawodników,
- historycznego charakteru danych obejmujących okres 1896–2016.

Graficzna analiza zależności wiek–BMI oraz wzrost–waga potwierdza ciągłość rozkładów oraz brak izolowanych, nielogicznych punktów danych. Obserwacje skrajne tworzą strukturalne obszary gęstości, a nie pojedyncze błędy pomiarowe. W związku z powyższym obserwacje nietypowe zostały zachowane w zbiorze danych jako integralny element rzeczywistej zmienności populacji badanej, a analiza anomalii została wykorzystana jako narzędzie weryfikacji jakości danych oraz pogłębionej interpretacji struktury zbioru danych.

7 Analiza braków danych

Analiza braków danych została przeprowadzona w celu identyfikacji skali niekompletności informacji, struktury braków oraz wzorców ich współwystępowania w zbiorze danych. Badanie obejmowało analizę ilościową, analizę wzorców braków oraz analizę strukturalną w kontekście zmiennych opisowych.

7.1 Analiza ilościowa braków danych

Wyniki ilościowej analizy braków danych wskazują, że największa niekompletność informacji dotyczy zmiennych opisujących cechy fizyczne zawodników oraz zmiennej medalowej. Jednak w przypadku zmiennej dotyczącej medali oznacza to, że nie zdobyto medalu, a nie faktyczny brak danych. Struktura braków przedstawia się następująco:

- **Medal**: 231 333 braki (**85,33%**) – brak medalu jako brak zdarzenia, a nie brak danych,
- **BMI**: 64 263 braki (**23,70%**),
- **Weight**: 62 875 braków (**23,19%**),
- **Height**: 60 171 braków (**22,19%**),
- **Age**: 9 474 braki (**3,49%**).

Pozostałe zmienne charakteryzują się pełną kompletnością danych (0% braków), co świadczy o wysokiej jakości strukturalnej zbioru danych w zakresie informacji identyfikacyjnych, czasowych i organizacyjnych.

7.2 Analiza wzorców braków danych

	ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Season	City	Sport	Event	Medal	Medal_status	BMI	HasMedal
ID																		
Name																		
Sex																		
Age				1.0	0.3139009861216339	0.3052813723236794									0.03736128722040548		0.3089052458189429	
Height				0.3139009861216339	1.0	0.942779892726144									0.002969224951644327		0.958207157720679	
Weight				0.3052813723236794	0.942779892726144	1.0									-0.002490883511222636		0.9858396758681821	
Team																		
NOC																		
Games																		
Year																		
Season																		
City																		
Sport																		
Event																		
Medal				0.03736128722040548	0.002969224951644327	-0.002490883511222636									1.0		-0.0038527869388688013	
Medal_status																		
BMI				0.3089052458189429	0.958207157720679	0.9858396758681821									-0.0038527869388688013		1.0	
HasMedal																		

Rysunek 8: Korelacje braków danych

W celu identyfikacji wzorców współwystępowania braków danych przeprowadzono analizę korelacji braków pomiędzy zmiennymi. Wyniki wskazują na bardzo silne współwystępowanie braków w zmiennych Height i Weight (współczynnik korelacji wynosi $\approx 0{,}94$), a także silne powiązanie braków w BMI z brakami w Height i Weight (korelacje odpowiednio $\approx 0{,}96$ oraz $\approx 0{,}99$).

Oznacza to, że braki w zmiennej BMI mają charakter wtórny i wynikają bezpośrednio z braków danych wejściowych (wzrostu i wagi), co jest konsekwencją konstrukcji tej zmiennej jako cechy syntetycznej.

Dodatkowo stwierdzono wysoką liczbę obserwacji z jednoczesnymi brakami w zmiennych Height i Weight (58 783 rekordy) oraz przypadków braków wieku współwystępujących z brakami cech fizycznych (8 786 rekordów), co potwierdza istnienie wspólnego mechanizmu generowania braków danych.

7.2.1 Analiza graficzna wzorców braków danych

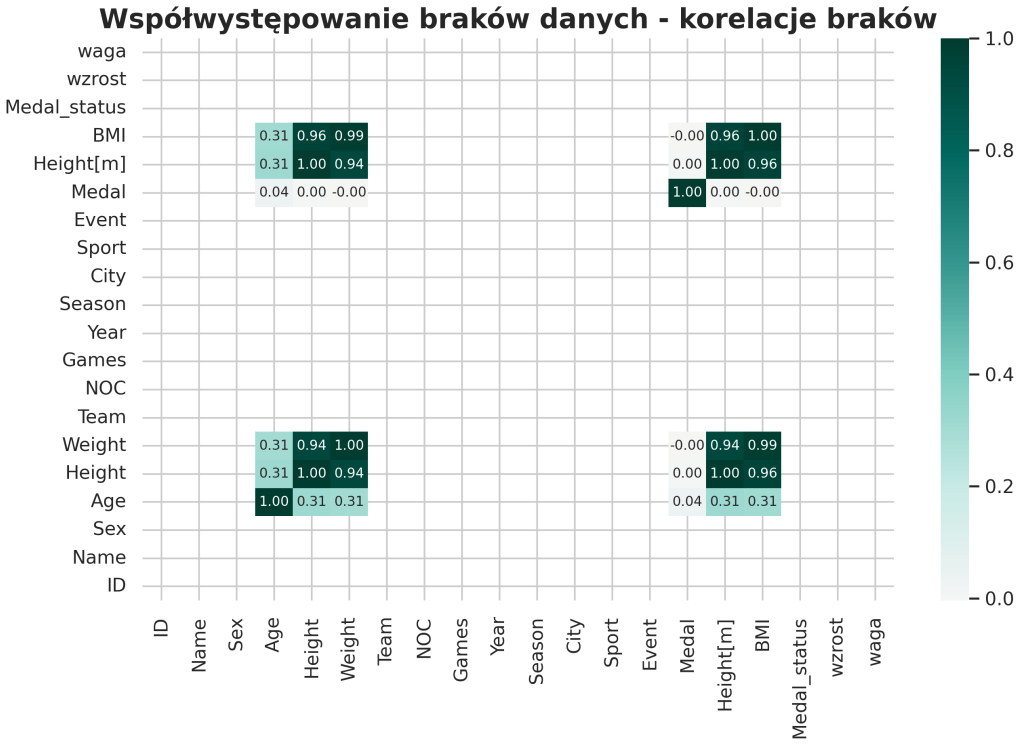

Rysunek 9: Wzorce braków danych

W celu wizualnej identyfikacji wzorców współwystępowania braków danych wykonano mapę cieplną (heatmap) korelacji braków pomiędzy zmiennymi. Wykres przedstawia stopień współwystępowania braków danych w poszczególnych kolumnach zbioru.

Analiza graficzna wykazała bardzo silne powiązania pomiędzy brakami w zmiennych Height i Weight, co potwierdza ich wspólny mechanizm generowania braków. Jednocześnie widoczna jest niemal idealna korelacja braków zmiennej BMI z brakami w Height oraz Weight, co wynika z konstrukcji zmiennej BMI jako cechy syntetycznej obliczanej na podstawie tych dwóch parametrów.

Wykres ujawnia również brak istotnych korelacji braków danych pomiędzy zmiennymi opisowymi (np. Team, NOC, Year, Sport, Event a zmiennymi fizycznymi, co wskazuje na brak losowych braków danych w tych obszarach zbioru.

Dodatkowo obserwuje się słabe lub zerowe powiązania braków w zmiennej Medal z innymi zmiennymi, co potwierdza, że wartości NA w tej kolumnie mają charakter braku zdarzenia (braku zdobycia medalu), a nie braków informacyjnych w sensie jakości danych.

Graficzna analiza wzorców braków danych potwierdza, że niekompletność informacji w zbiorze danych ma charakter strukturalny i systemowy, a nie losowy, co jest spójne z wynikami analizy ilościowej i strukturalnej braków danych.

7.3 Analiza strukturalna braków danych

Analiza braków danych w ujęciu strukturalnym, z uwzględnieniem zmiennej Sport, wykazała silne zróżnicowanie poziomu braków w zależności od dyscypliny sportowej. W szczególności w dyscyplinach takich jak Aeronautics, Alpinism, Basque Pelota, Roque, Cricket, Croquet oraz Art Competitions stwierdzono niemal całkowity brak danych dotyczących wzrostu i wagi zawodników (często 100% braków).

Wysoki poziom braków w tych kategoriach wynika z historycznego charakteru zbioru danych, specyfiki konkurencji (np. konkurencje artystyczne, dyscypliny nieoparte na parametrach fizycznych) oraz braku standaryzacji pomiarów cech fizycznych w początkowych okresach nowożytnych igrzysk olimpijskich.

Zawody w kategorii Aeronautics odbyły się tylko raz w historii igrzysk, wystąpił na nich wyłącznie jeden zawdonik - był to Hermann Schreiber, który w ramach Igrzysk otrzymał medal za przelot nad Alpami, który wykonał wcześniej. Jest jedynym zawodnikiem w tej kategorii, nie ma uzupełnionego wzrostu oraz wagi. Stąd wynika 100% brak danych w kategorii Aeronautics.

Wysoki poziom braków w tych kategoriach wynika z historycznego charakteru zbioru danych, specyfiki konkurencji (np. konkurencje artystyczne, dyscypliny nieoparte na parametrach fizycznych) oraz braku standaryzacji pomiarów cech fizycznych w początkowych okresach nowożytnych igrzysk olimpijskich.

```
brak wagi      False  True
brak wzrostu
False         206853   4092
True            1388  58783
szansa na brak wagi przy braku wzrostu: 97.69%
szansa na brak wzrostu przy braku wagi: 93.49%
```

Rysunek 10: Tabela przestawna braków

- 206 853 rekordów (**76,3%**) posiada dane zarówno w kategorii wzrost, jak i waga;
- 58 783 rekordów (**21,68%)** posiada braki w obydwu kategoraich;
- 4 092 rekordów (**1,51%**) ma dane w kategorii wzrost, lecz braki w wadze;
- 1 388 rekordów (**0,52%**) ma dane w kategorii waga, lecz braki we wzroście;

Spośród rekordów, które mają brak wzrostu, 97,69% również ma braki w wadze.

Spośród rekordów, które mają brak wagi, 93,49% również ma braki we wzroście.

Istnieje silna zależność, jeżeli rekord nie ma wzrostu, to jest bardzo duża szansa, że nie będzie miał też wagi oraz jeżeli rekord nie ma wagi, to jest również bardzo duża szansa (choć odrobinę mniejsza), że nie będzie miał też wzrostu.

7.4 Wzrost

Najwięcej braków jest w kolumnie Height. Sprawdzono sensowność uzupełnienia wzrostu zawodnika średnim wzrostem dorosłej populacji jego płci w jego kraju w danym roku. W tym celu policzono średnią wzrostu wszystkich sportowców dla danego kraju, dla danej płci oraz dla danego roku.

7.4.1 Japonia

```
Liczba zawodnikow JPN: 171
Średni wzrost: 174.63 cm
```

Rysunek 11: Średni wzrost zawodników w 2016 - Japonia

Dla populacji sportowców płci męskiej z Japonii w 2016 roku średnia wzrostu wyniosła 174,63 cm. Podczas gdy średnia wzrostu ogółu mężczyzn w Japonii w roku 2016 wynosiła 171,91 cm. Wiek jest podany dla 19-latków, jednak jest to wiek w którym człowiek osiągnął już swój docelowy wzrost. Różnica między wzrostem zawodnika igrzysk z Japonii a przeciętnym mieszkańcem kraju wyniosła 2,72 cm.

```
sportowcy JPN wg dyscyplin:
            Sport  ID
        Athletics  37
         Swimming  18
         Football  17
     Rugby Sevens  12
       Water Polo  12
          Cycling   8
             Judo   7
    Equestrianism   7
       Gymnastics   5
         Shooting   5
          Sailing   5
         Canoeing   4
        Badminton   4
        Wrestling   4
    Weightlifting   3
           Tennis   3
     Table Tennis   3
```

Rysunek 12: Liczba zawodników wg dyscyplin w 2016 - Japonia

7.4.2 Polska

Z kolei dla populacji sportowców z Polski średnia wzrostu wyniosła 188,10 cm. Jednocześnie dla ogółu mężczyzn w Polsce w roku 2016 średnia wzrostu wynosiła 180,21 cm.

```
Liczba zawodnikow POL: 139
Średni wzrost: 188.10 cm
```

Rysunek 13: Średni wzrost zawodników w 2016 - Polska

Różnica między wzrostem zawodnika igrzysk z Polski a przeciętnym mieszkańcem kraju wyniosła aż 7,89 cm.

```
łączna liczba sportowców w kadrze: 139
sportowcy POL wg dyscyplin:
           Sport  ID
       Athletics  35
          Rowing  16
        Handball  15
        Swimming  13
      Volleyball  12
        Canoeing   9
         Cycling   7
       Badminton   4
```

Rysunek 14: Liczba zawodników wg dyscyplin w 2016 - Polska

Po zagłębieniu się w strukturę polskich zawodników płci męskiej na Igrzyskach w roku 2016 okazuje się, że 16 z nich stanowią kajakarze, 15 zawodnicy piłki ręcznej, a 12 zawodnicy piłki siatkowej. Są to sporty znane z tego, że ich zawodnicy cechują się wysokim wzrostem. Z kolei wśród mężczyzn z Japonii na Igrzyskach w roku 2016 nie było szczypiornistów ani siatkarzy. Było jedynie dwóch kajakarzy.

```
Liczba zawodnikow POL: 96
Średni wzrost: 185.63 cm
```

Rysunek 15: Średni wzrost zawodników bez kajakarzy, siatkarzy i szczypiornistów w 2016 - Polska

Gdyby usunąć zawodników kajakarstwa, piłki siatkowej i piłki ręcznej, średni wzrost zawodników spada do 185,63 cm i różni się już o 5,42 cm od średniej dla ogółu męskiej populacji kraju.

7.4.3 USA

```
Liczba zawodnikow USA: 264
Średni wzrost: 184.56 cm
```

Rysunek 16: Średni wzrost zawodników w 2016 - USA

Średni wzrost sportowca z USA na Igrzyskach w 2016 wyniósł 184,56 cm. Średni wzrost mieszkańca USA 176,53 cm. Zawodnik był średnio o 8,03 cm wyższy od średniego mieszkańca kraju.

```
Łączna liczba sportowców w kadrze: 264
sportowcy USA wg dyscyplin:
            Sport  ID
        Athletics  64
         Swimming  25
           Rowing  21
     Rugby Sevens  13
         Shooting  13
       Water Polo  13
       Basketball  12
       Volleyball  12
        Wrestling  10
          Sailing   8
          Cycling   8
          Fencing   7
    Equestrianism   6
           Boxing   6
           Tennis   5
       Gymnastics   5
           Diving   5
 Beach Volleyball   4
             Golf   4
```

Rysunek 17: Liczba zawodników wg dyscyplin w 2016 - USA

Wśród zawodników ze USA również możemy zauważyć dosyć dużo zawodników z kajakarstwa, piłki koszykowej oraz piłki siatkowej.

```
Liczba zawodnikow USA: 219
Średni wzrost: 182.96 cm
```

Rysunek 18: Średni wzrost zawodników bez koszykarzy, siatkarzy i kajakarzy z 2016 - USA

Po usunięciu zawodników piłki siatkowej, koszykowej oraz kajakarstwa, średni wzrost spada do 182,96 i różni się od ogółu populacji o 6,03 cm.

7.4.4 Wnioski

Przeprowadzona analiza porównawcza średniego wzrostu sportowców olimpijskich z wybranych krajów (Japonia, Polska, USA) z przeciętnym wzrostem ogółu populacji męskiej w tych krajach wskazuje, że uzupełnianie braków danych wzrostu na podstawie średnich krajowych nie jest metodologicznie uzasadnione.

We wszystkich analizowanych przypadkach średni wzrost zawodników olimpijskich istotnie odbiegał od średniego wzrostu populacji ogólnej, przy czym skala tej różnicy była silnie uzależniona od struktury dyscyplin sportowych reprezentowanych przez dany kraj.

Dodatkowo wykazano, że nawet po częściowym wykluczeniu dyscyplin o ponadprzeciętnie wysokim wzroście zawodników, średni wzrost sportowców nadal pozostaje wyższy od średniego wzrostu ogółu populacji.

W związku z powyższym uzupełnianie braków danych wzrostu przy użyciu średnich krajowych (lub średnich populacyjnych zależnych od płci i roku) prowadziłoby do zaniżania wzrostu zawodników olimpijskich oraz do zniekształcenia rozkładów cech fizycznych w zbiorze danych. Na podstawie przeprowadzonej analizy zdecydowano o rezygnacji z imputacji brakujących wartości wzrostu metodami opartymi na średnich populacyjnych.

Kraje z największą różnicą wzrostu wśród mężczyzn

Państwo	Płeć	Średni wzrost zawodnika	Liczba zawodników	Średni wzrost mieszkańca	Różnica [cm]
Cote d'Ivoire	M	185.50	6	167.81	17.68
Niger	M	185.75	4	169.89	15.85
Benin	M	183.75	4	168.03	15.71
Tajikistan	M	183.40	5	168.00	15.39
Burkina Faso	M	185.33	3	171.36	13.96
Turkmenistan	M	187.25	4	173.79	13.45
Qatar	M	185.27	40	172.41	12.86
Albania	M	186.0	3	173.59	12.40
Pakistan	M	179.00	3	166.65	12.34
Ghana	M	182.00	3	170.00	11.99

Kraje z największą różnicą wzrostu wśród kobiet

Państwo	Płeć	Średni wzrost zawodniczki	Liczba zawodniczek	Średni wzrost mieszkanki	Różnica [cm]
Burundi	F	171.00	4	154.96	16.03
Angola	F	173.88	18	157.95	15.93
Senegal	F	178.06	16	163.95	14.10
Cameroon	F	173.94	17	160.34	13.59
Barbados	F	178.80	5	165.37	13.42
Guinea	F	172.00	3	158.90	13.09
Puerto Rico	F	175.25	27	162.76	12.49
Nigeria	F	169.70	27	158.01	11.69
Nepal	F	163.25	4	151.96	11.28
Cambodia	F	165.25	4	154.14	11.10

Kraje z najmniejszą różnicą wzrostu wśród mężczyzn

Państwo	Płeć	Średni wzrost zawodnika	Liczba zawodników	Średni wzrost mieszkańca	Różnica [cm]
Cook Islands	M	177.25	4	177.88	-0.63
Ukraine	M	179.58	126	180.34	-0.75
Dominican Republic	M	173.13	22	173.98	-0.84
Guyana	M	170.66	3	171.53	-0.87
Samoa	M	173.33	3	174.28	-0.95
Antigua and Barbuda	M	177.33	6	178.38	-1.05
Netherlands	M	182.38	149	183.60	-1.21
Switzerland	M	177.15	91	178.60	-1.45
Tanzania	M	164.66	3	166.65	-1.98
North Korea	M	164.30	13	173.91	-9.60

Kraje z najmniejszą różnicą wzrostu wśród kobiet

Państwo	Płeć	Średni wzrost zawodniczki	Liczba zawodniczek	Średni wzrost mieszkanki	Różnica [cm]
Trinidad and Tobago	F	164.05	18	163.07	0.97
Malta	F	163.50	4	162.84	0.65
Bermuda	F	166.25	4	165.83	0.41
Central African Republic	F	159.66	3	159.67	-0.00
United Arab Emirates	F	160.00	3	160.05	-0.05
Lebanon	F	162.50	4	163.09	-0.59
Armenia	F	159.10	10	159.75	-0.65
Guyana	F	158.00	4	159.22	-1.22
North Korea	F	158.72	25	160.64	-1.92
Palau	F	157.00	3	159.19	-2.19

W roku 2016 różnica średniej wzrostu zawodnika względem średniej wzrostu mieszkańca kraju sięga nawet kilkunsatu centymetrów. Co ciekawe, w niektórych krajach okazuje się, że średni wzrost zawodnika był niższy niż średni wzrost mieszkańca.

7.5 Imputacja braków danych

Średni wzrost wszystkich sportowców w całej historii Igrzysk to 175,34 cm. Zostały wykonane następujące mapowania:

- "Czechoslovakia": "Czech Republic",
- "Union des Socits Franais de Sports Athletiques": "France",
- "Devon and Somerset Wanderers": "United Kingdom",
- "Quicksilver-2": "United Kingdom",
- "Great Britain": "United Kingdom",
- "United States": "United States of America"

Występuje brak danych dla sportu Krykiet, ponieważ występował on jedynie na Olimpiadzie w roku 1900. Udział w nim brało 24 sportowców. Ich zespół to "Union des sociétés françaises de sports athlétiques", który został ręcznie zmapowany jako Francja i dane zostały zimputowane średnim wzrostem dla Francuzów.
Brak danych dla sportu Patrol wojskowy, ponieważ występował on jedynie na Olimpiadzie w roku 1924. Występowało w nim 24 zawodników, każdy z nich ma braki we wzroście. Imputowano średni wzrost mieszkańca danego kraju o danej płci, z roku 1985 (najbliższe dane od roku 1924).
Czechosłowacja, która już nie istnieje oraz nie ma danych dotyczących wzrostu, została zmapowana na Republikę Czech.
Krokiet występował w roku 1900, łącznie uczestniczyło w nim 19 zawodników. Algorytm wpisał średni wzrost z ich krajów. Wszyscy byli z Francji, a średni wzrost we Francji w najbliższym roku (1985) wynosił 176,09 cm dla mężczyzn i 163,24 cm dla kobiet. Został on powiększony o 5,95cm, ponieważ średnio o tyle historycznie różnił się olimpijczyk z danego kraju od średniego obywatela swojego kraju danej płci i wyniósł odpowiednio 182 cm dla mężczyzn i 169,2 cm dla kobiet.
Dla sportu Alpinizm również został wpisany średni wzrost z danych krajów, ponieważ sportowców było łącznie 25 i żaden nie miał wpisanego wzrostu. Dane dla zawodników z Wielkiej Brytanii zostały zmapowane na "Great Britain", ponieważ pod taką nazwą są dane w średnich wzrostach 19-latków.
Została również zmapowana drużyna "Quicksilver-2"na United Kingdom, i dzięki tym kilku ręcznym zabiegom, nigdzie nie została wpisana średnia globalna wzrostu olimpijczyków (175,34 cm), tylko zawsze dla odpowiednich krajów.

7.6 Charakter braków danych

Na podstawie przeprowadzonej analizy braków danych dokonano ich klasyfikacji metodologicznej. Braki danych nie mają charakteru losowego (MCAR), lecz wykazują cechy braków typu MAR (Missing At Random), zależnych od innych zmiennych obserwowalnych, takich jak dyscyplina sportowa, charakter konkurencji oraz okres historyczny.

Braki te mają charakter strukturalny i systemowy, a nie przypadkowy, co wyklucza ich interpretację jako błędów danych.

8 Wybór zmiennych i rekordów do przykładowej analizy

Zgodnie z założeniami projektu sformułowano pytania badawcze. Celem było przygotowanie zbioru danych, który może zostać wykorzystany w przyszłości do budowy modeli statystycznych odpowiadających na postawione pytania.

8.1 Pytania badawcze

- W jakich kategoriach sportowych wysoki wzrost zawodnika pomaga mu w zdobyciu medalu?
- W jakich kategoriach sportowych niski wzrost zawodnika pomaga mu w zdobyciu medalu?

8.2 Wybór rekordów do analizy

Do przygotowania zbioru pod przyszłe modelowanie wykorzystano obserwacje dotyczące wzrostu zawodnika.

8.3 Wybór zmiennych do analizy

Do analizy wybrano poniższe zmienne:

- **Zmienna wynikowa:** Medal Status (kolumna z zastąpionymi NA na No Medal)
- **Zmienna główna:** Height (wzrost w cm)
- **Zmienna grupująca efekt:** Sport (zmienna umożliwiająca modelowanie różnic efektu wzrostu między sportami)
- **Zmienne kontrolne:** Sex, Age

9 Źródła

- Zbiór danych *120 Years of Olympic History* - link
- Zbiór danych *Height Evolution of adult height over time* - link
- Zawodnicy
  - John Quincy Adams Ward - link
  - Dimitrios Loundras - link
  - Yao Ming - link
  - Rosario Briones - link
  - Choi Gyong-hui - link
  - Ricardo Blas Jr. - link
- Igrzyska Olimpisjkie 2016 Rio - link
- Igrzyska Olimpijskie 1936 Aeronautyka - link
- Igrzyska Olimpijskie Czechosłowacja - link
- Igrzyska Olimpijskie 1900 Krykiet - link
- Igrzyska Olimpisjkie 1928 Konkurs Sztuki i Literatury - link
- Unia Francuskich Towarzystw Sportów Atletycznych - link
- Patrol wojskowy - link
- Prezentacje udostępnione w zespole przedmiotu *Przygotowanie i walidacja danych*
- Dokumentacja *pandas* - link
- Dokumentacja *numpy* - link